



Modélisation d'un détecteur de Faux billets

ONCFM



Modèles
d'apprentissage
supervisé
et non supervisé






- I – Présentation
 - I.A - Contexte
 - I.B - Méthodologie
 - I.C - Documentation RGPD (ANNEXE)
- II – Analyse Exploratoire des données (EDA)
- III– Modélisation basée sur le K-means
- IV – Modélisation supervisée
- V – Choix du modèle final
- VI – Présentation de l'application
- VII – Conclusion et Perspectives



- Entreprise :
 - **Organisme Nationale de Lutte contre le Faux Monnayage**
 - **Activité** : Identification des contrefaçons de billets en euros
- BESOIN :
 - Mise à disposition d'un algorithme **prédisant l'authenticité** des billets.
- OBJECTIFS :
 - Une **application de Machine Learning**
 - **prédisant l'authenticité** d'un billet
 - à partir des **caractéristiques géométriques** d'un billet
 - respectant le cahier des charges fourni







- I – Présentation
- II – Analyse Exploratoire des Données (EDA) et Traitements de données
 - II.A – EDA : Premières données chiffrées
 - II.B – EDA : Analyse Univariée et multivariée (Visualisation)
 - II.C-Traitement des Valeurs Manquantes : Régression Linéaire multiple
 - II.D – EDA Vue globale des données d'études
- III – Modélisation basée sur le K-means
- IV – Modélisation supervisée
- V – Choix du modèle final
- VI – Présentation de l'application
- VII – Conclusion et Perspectives

II.A – EDA : Premières données chiffrées

DONNEES

○ Variable Qualifiant l'authenticité réelle :

- **is_genuine** : Bool (True/I/Vrai billet)

○ Données Géométriques des billets (en mm):


- **length** : longueur
- **height_left** : hauteur mesurée côté gauche
- **height_right** : hauteur mesurée côté droit
- **margin_up** : marge bord supérieur-image
- **margin_low** : marge bord inférieur-image
- **diagonal** : diagonale

	Type	Nb lignes	Valeurs non-vides	Valeurs vides	Valeurs distinctes
is_genuine	bool	1500	1500	0	2
diagonal	float64	1500	1500	0	159
height_left	float64	1500	1500	0	155
height_right	float64	1500	1500	0	170
margin_low	float64	1500	1463	37	285
margin_up	float64	1500	1500	0	123
length	float64	1500	1500	0	336

	count	mean	std	min	25%	50%	75%	max	IQ	min-Q1/IQ	Q3-max/IQ
diagonal	1500.0	171.958440	0.305195	171.04	171.750	171.96	172.17	173.01	0.420	1.690476	2.000000
height_left	1500.0	104.029533	0.299462	103.14	103.820	104.04	104.23	104.88	0.410	1.658537	1.585366
height_right	1500.0	103.920307	0.325627	102.82	103.710	103.92	104.15	104.95	0.440	2.022727	1.818182
margin_low	1463.0	4.485967	0.663813	2.98	4.015	4.31	4.87	6.90	0.855	1.210526	2.374269
margin_up	1500.0	3.151473	0.231813	2.27	2.990	3.14	3.31	3.91	0.320	2.250000	1.875000
length	1500.0	112.678500	0.872730	109.49	112.030	112.96	113.34	114.44	1.310	1.938931	0.839695


- 1500 billets (1000V, 500F)
- 37 val manquantes (margin_low)
- Mêmes ordre de grandeur
- Pas de doublon
- Règle de Tukey :
Pas de valeur aberrante
(min-Q1/IQ, Q3-max)/IQ < 3

Répartition de l'authenticité des billets




II.B – EDA : Analyse Univariée et multivariée (Visualisation)

Boxplot des variables quantitatives selon l'authenticité des billets




- Des outliers mais pas de valeur aberrante
- Diff de répartition selon authenticité

Pairplot des variables géométriques selon l'authenticité



Corrélation entre les variables



- **Corrél. lin. is_genuine et [length, margin_low]**
- **Pas de corrélation signif. entre var géométriques (légère length/margin_low)**

II.C – Traitement des Valeurs Manquantes : Régression Linéaire Multiple

• Conditions Préalables



- Données manquantes : margin_low : 37
- Qté suffisantes données connues : 1463
- Var cible numérique continue: margin_low
- Var prédictives numériques :
 - Discrète : is_genuine
 - Continue : var géométriques
- Absence de données aberrantes : $(Q1 - \min/IQ, \max - Q3/IQ) < 3$

• Choix du modèle

- SCALER** : Non Nécessaire
- VAR PREDICTIVES CRITERES** :
 - $|corr| > 0.3$ avec var cible
 - $|corr| < 0.8$ entre elles
 - cohérence sens géométriques
- VARIABLES PREDICTIVES** :
 - Uniquement var géom continue:
 - 'length', 'margin_up', 'height_right'
 - 'length', 'margin_up', 'height_right', 'height_left'
 - Toutes var numériques :
 - "is_genuine", 'margin_up', 'height_right'

	Modèle A	Modèle B	Modèle C
Scaler	Non	Non	Non
Var pred	'length', 'margin_up', 'height_right'	'length', 'margin_up', 'height_right', 'height_left'	'is_genuine', 'margin_up', 'height_right'
Coefficient y =	-0.43 * length + 0.28 * margin_up + 0.27 * height_right + 23.18	-0.41 * length + 0.26 * margin_up + 0.25 * height_right + 0.18 * height_left + 5.27	-1.15 * is_genuine - 0.21 * margin_up + 0.03 * height_right + 3.04
R ²	0.4691	0.4748	0,61
MAPE	8,3%	8,25%	7,03%
Non Colin (VIF)	OK VIF proches de 1	OK VIF proches de 1	OK VIF proches de 1
Normalité Résidus Sch	KO (p-val<0.05)	KO (p-val<0.05)	KO (p-val<0.05)
Homosced Résidus B-P	KO (p-val<0.05)	KO (p-val<0.05)	KO (p-val<0.05)

- Meilleur Modèle (R², MAPE) => Modèle C choisi
- Hypothèses KO / bon R², et MAPE :
=> Rempl des valeurs OK, sans interpretation des coeff




II.D – EDA Vue globale des données d'études

DONNEES COMPLETES





	Type	Nb lignes	Valeurs non-vides	Valeurs vides	Valeurs distinctes
is_genuine	bool	1500	1500	0	2
diagonal	float64	1500	1500	0	159
height_left	float64	1500	1500	0	155
height_right	float64	1500	1500	0	170
margin_low	float64	1500	1500	0	322
margin_up	float64	1500	1500	0	123
length	float64	1500	1500	0	336

	count	mean	std	min	25%	50%	75%	max	IQ	min-Q1/IQ	Q3-max/IQ
diagonal	1500.0	171.958440	0.305195	171.04	171.7500	171.96	172.17	173.01	0.4200	1.690476	2.000000
height_left	1500.0	104.029533	0.299462	103.14	103.8200	104.04	104.23	104.88	0.4100	1.658537	1.585366
height_right	1500.0	103.920307	0.325627	102.82	103.7100	103.92	104.15	104.95	0.4400	2.022727	1.818182
margin_low	1500.0	4.482858	0.659857	2.98	4.0275	4.31	4.87	6.90	0.8425	1.243323	2.409496
margin_up	1500.0	3.151473	0.231813	2.27	2.9900	3.14	3.31	3.91	0.3200	2.250000	1.875000
length	1500.0	112.678500	0.872730	109.49	112.0300	112.96	113.34	114.44	1.3100	1.938931	0.839695

- 1500 billets (1000 V, 500F)
- 0 val manquantes
- Mêmes ordre de grandeur
- Règle de Tukey :
Pas de valeur aberrante
(min-Q1/IQ), Q3-max/IQ < 3



VISUALISATIONS






- I – Présentation
- II – Analyse Exploratoire des Données (EDA) et Traitements de données
- III – Modélisation basée sur le K-means
 - III.A-Méthodologie de Modélisation K-Means
 - III.B –Modélisation K-Means et Performances
 - III.C – REMARQUE sur le modèle basé sur le K-means
- IV – Modélisation supervisée
- V – Choix du modèle final
- VI – Présentation de l'application
- VII – Conclusion et Perspectives



III.A – Méthodologie de Modélisation K-Means :



III.B – Modélisation K-Means et Performances

PARAMÉTRISATION

○ SPLIT JEUX DONNEES




- Split : 80% Train / 20% test
- RS=42

○ TRANSF° DONNEES :


- StandardScaler
- ACP (3axes)

○ NBR CLUSTER : 2

- Coude / silhouette
- Sens



ÉVALUATION DE PERFORMANCE



Authen-ticité :	MATRICE de CONFUSION	
FAUX Billet	TN	FP
VRAI Billet	FN	TP
Prédic° =>	Négatif Faux Prédit	Positif Vrai Prédit

Score	Perf
Exactitude	98,7 %
Précision	98,9 %
TPR(Recall)	98,9 %
FPR	1,8 %
Pseudo ROC AUC	0,978

- 98,7% d'échantillons bien classés
- 98,9% des Positifs détectés sont des Vrais billets(TP)
- 98,9% des Vrais billets sont bien classés (TP)
- 1,8% des Faux billets sont mal classés (FP)
- Bon pseudo ROC AUC près de 1


III.C – REMARQUE sur le modèle basé sur le K-means

- **Très Bon résultat sur des données bien séparées.**
- **Données mal séparées ne seront pas clusterisées efficacement :**
 - ex tous les Vrais billets sont proportionnels (simplement extension ou rétrécissement proportionnel)
les vrais billets seraient le long d'une droite (largeur longueur).
 - les faux billets sont dispersés de part et d'autre de la droite, les clusters ne sauront pas bien regrouper les 2 blocs, et les isobarycentres peuvent être proches
- **Méthode des centroïdes limitées :**
 - Centroïdes calculés : isobarycentre d'un cluster (combinant Vrai et Faux billets),
si les Vrai et Faux billets sont mal séparés, on peut imaginer 51 Vrai et 49 Faux pour Clust1 (49V, 51F pr Clust0)
(ex de Faux billets qui sont proportionnellement plus grand que les Vrais billets)
=> Renforce les traits principaux de chacune des catégories.
 - Possibilité simple de calculer les centroïdes comme isobarycentre des Vrais et Faux billets (plus nuancé)
 - Possibilité d'avoir des centroïdes très proches séparant mal les Vrai et Faux billets
- **Complexité supplémentaire de Conversion Cluster/Prédiction**
- **Pas de probabilité réelle**
- **Pas le même système d'amélioration type GridsearchCV**
- **Fonctionne pour des cas particuliers où les données sont « séparables par une droite ».**
- **Le terme non supervisé est impropre :** le K-means est non supervisé, (et donne un résultat juste avec X_{train_tr} sans utiliser y_{train})
mais la modélisation K-means est supervisée, elle utilise y_{train} , pour la conversion Cluster/Prediction,
et la modélisation bénéficie donc du test sur X_{test_tr} , y_{test} pour sa prédiction sur X_{test}



- I – Présentation
- II – Analyse Exploratoire des Données (EDA) et Traitements de données
- III – Modélisation basée sur le K-means
- IV – Modélisation supervisée
 - IV.A – Méthodologie de Modélisation
 - IV.B – Régression Logistique : Choix de Variable et de Scaler
 - IV.C – Régression Logistique Améliorée
 - IV.D – Random Forest Amélioré
 - IV.E – K Nearest Neighbors Amélioré
- V – Choix du modèle final
- VI – Présentation de l'application
- VII – Conclusion et Perspectives

IV.A – METHODOLOGIE DE MODELISATION :



IV.B – Régression Logistique : Choix de Variable et de Scaler :



Modèle A : TTE Var Géom - Non Scalée

Paramétrisation

- CHOIX VAR : TTES VAR Géom :
'diagonal', 'length', 'height_left', 'height_right', 'margin_low', 'margin_up'
- TRANSF° DONNEES :
 - Scaler : NON

EVALUATION PERFORMANCE

Score	Perf
Exactitude	99 %
Précision	98,4 %
TPR(Recall)	100 %
FPR	2,7 %
ROC AUC	0,9997



Modèle B : TTE Var Géom - StandardScaler



Paramétrisation

- CHOIX VAR : TTES VAR Géom :
'diagonal', 'length', 'height_left', 'height_right', 'margin_low', 'margin_up'
- TRANSF° DONNEES :
 - Scaler : StandardScaler

Choix pr tous modèles pour comparaison

EVALUATION PERFORMANCE

Score	Perf
Exactitude	99,33 %
Précision	98,96 %
TPR(Recall)	100 %
FPR	1,8 %
ROC AUC	0,9999





Modèle C : Sans 'diagonal' - StandardScaler

Paramétrisation

- CHOIX VAR : VAR Géom Sans 'diagonal' :
'length', 'height_left', 'height_right', 'margin_low', 'margin_up'
- TRANSF° DONNEES :
 - Scaler : StandardScaler

EVALUATION PERFORMANCE

Score	Perf
Exactitude	99,33 %
Précision	98,96 %
TPR(Recall)	100 %
FPR	1,8 %
ROC AUC	0,9999



IV.C –Regression Logistique Améliorée

Modèle B : TTE Var Géom – StandardScaler

Vérif ROBUSTESSE(Valid° croisée)

- Robustesse aux différents type de split : OK
- Robustesse aux RS de la régression Logistique : OK

CHOIX Meilleurs Paramètres avec GridSearchCV




- **OBJECTIF :** meilleur ROC AUC
- **MEILLEURS PARAMETRES :**
 - C : 0.1 (param correctif de l2)
 - Max_iter : 100
 - Penalty : 'l2' (type de correction)
- **AJUSTEMENT DU SEUIL :**
 - Seuil de proba à 0.5 ok

Seuil 0.30	→ TPR : 1.00	FPR : 0.08
Seuil 0.40	→ TPR : 1.00	FPR : 0.04
Seuil 0.50	→ TPR : 1.00	FPR : 0.03
Seuil 0.60	→ TPR : 0.99	FPR : 0.01
Seuil 0.70	→ TPR : 0.98	FPR : 0.01

EVALUATION PERFORMANCE

Score	Perf
Exactitude	99 %
Précision	98,45 %
TPR(Recall)	100 %
FPR	2,7 %
ROC AUC	0,9998

- 99% d'échantillons bien classés
- 98,45% des Positifs détectés sont des Vrais billets (TP)
- 100% des Vrais billets sont bien classés (TP)
- 2,7% des Faux billets sont mal classés (FP)
- Bon ROC AUC : 0,9998
- Proba confiante



IV.D – Random Forest Amélioré

Modèle : TTE Var Géom – StandardScaler

Vérif ROBUSTESSE(Valid° croisée)

- Robustesse aux différents type de split : OK
- Robustesse aux RS du modèle : OK

CHOIX Meilleurs Paramètres avec GridSearchCV




- **OBJECTIF :** meilleur ROC AUC
- **MEILLEURS PARAMETRES :**
 - 'criterion': 'entropy'
 - 'max_depth': 10
 - 'max_features': 2
 - 'min_samples_split': 2
 - 'n_estimators': 500
- **AJUSTEMENT DU SEUIL :**
 - Seuil de proba à 0.5 ok

Seuil 0.30 → TPR : 1.00 | FPR : 0.04
Seuil 0.40 → TPR : 1.00 | FPR : 0.04
Seuil 0.50 → TPR : 1.00 | FPR : 0.02
Seuil 0.60 → TPR : 1.00 | FPR : 0.02
Seuil 0.70 → TPR : 0.99 | FPR : 0.00

EVALUATION PERFORMANCE

Score	Perf
Exactitude	99,33 %
Précision	98,96 %
TPR(Recall)	100 %
FPR	1,8 %
ROC AUC	0,9999

- 99,33% d'échantillons bien classés
- 98,96% des Positifs détectés sont des Vrais billets(TP)
- 100% des Vrais billets sont bien classés (TP)
- 1,8% des Faux billets sont mal classés (FP)
- Bon ROC AUC : 0,9999
- Proba confiante



IV.E – K-Nearest Neighbors Amélioré

Modèle : TTE Var Géom – StandardScaler

Vérif ROBUSTESSE(Valid° croisée)

- Robustesse aux différents type de split : OK

CHOIX Meilleurs Paramètres avec GridSearchCV




- **OBJECTIF :** meilleur ROC AUC
- **MEILLEURS PARAMETRES :**
 - 'metric': 'minkowski'
 - 'n_neighbors': 9
 - 'p': 1
 - 'weights': 'uniform'
- **AJUSTEMENT DU SEUIL :**
 - Meilleur seuil à 0.6 => pour des raisons de simplicité et comparaison resteront à 0.5

Seuil 0.30	→ TPR : 1.00	FPR : 0.05
Seuil 0.40	→ TPR : 1.00	FPR : 0.05
Seuil 0.50	→ TPR : 1.00	FPR : 0.04
Seuil 0.60	→ TPR : 1.00	FPR : 0.02
Seuil 0.70	→ TPR : 0.99	FPR : 0.02

EVALUATION PERFORMANCE

Score	Perf
Exactitude	98,67 %
Précision	97,93 %
TPR(Recall)	100 %
FPR	3,6 %
ROC AUC	0,9996

- **98,67%** d'échantillons bien classés
- **97,93%** des Positifs détectés sont des Vrais billets(TP)
- **100%** des Vrais billets sont bien classés (TP)
- **3,6%** des Faux billets sont mal classés (FP)
- **Bon ROC AUC : 0,9996**
- Proba confiante





- I – Présentation
- II – Analyse Exploratoire des Données (EDA) et Traitements de données
- III – Modélisation basée sur le K-means
- IV – Modélisation supervisée
- V – Choix du modèle final
- VI – Présentation de l'application
- VII – Conclusion et Perspectives





V – Choix du modèle final

COMPARAISON PERFORMANCE

Score	K-means	Reg Log	Random Forest	KNN
Exactitude	98,7 %	99 %	99,33 %	98,67 %
Précision	98,9 %	98,45 %	98,96 %	97,93 %
TPR(Recall)	98,9 %	100 %	100 %	100 %
FPR	1,8 %	2,7 %	1,8 %	3,6 %
ROC AUC	0,978	0,9998	0,9999	0,9996

CHOIX : RANDOM FOREST

- **Random Forest : modèle le plus fiable**
 - Meilleur sur tous les scores !
 - Très faible acceptation de Faux billets (FPR=1.8%)
 - Aucun rejet de vrai billet (TPR = 1.0)
 - **Le K-means :**
alternative simple et robuste, même sans supervision.
 - **La Régression Logistique :**
explicable mais plus risquée en FPR.
 - **Le KNN :**
performant, mais FPR moins adapté ici.
- => Choix recommandé : Random Forest**
- **99,33%** d'échantillons bien classés
 - **98,96%** des Positifs détectés sont des Vrais billets (TP)
 - **100%** des Vrais billets sont bien classés (TP)
 - **1,8%** des Faux billets sont mal classés (FP)
 - **ROC AUC : 0,9999** quasi parfait
 - Proba confiante





- I – Présentation
- II – Analyse Exploratoire des Données (EDA) et Traitements de données
- III – Modélisation basée sur le K-means
- IV – Modélisation supervisée
- V – Choix du modèle final
- VI-Présentation de l'application
- VII-Conclusion et Perspectives



VI – Présentation de l'application

0. TYPE DE FICHIER D'ENTREE :

diagonal	height_left	height_right	margin_low	margin_up	length	id
171.76	104.01	103.54	5.21	3.30	111.42	A_1
171.87	104.17	104.13	6.00	3.31	112.09	A_2
172.00	104.58	104.29	4.99	3.39	111.57	A_3
172.49	104.55	104.34	4.44	3.03	113.20	A_4
171.65	103.63	103.56	3.77	3.16	113.33	A_5

1. Déposer le Fichier dans le dossier Adéquate


CHEMIN A COMPLETER LORS DE LA SOUTENANCE

```
#Import du fichier billets Soutenance

#EN ATTENTE DU FICHIER/CHEMIN A REMPLIR : fichier à déposer dans D:\BDD\OCR\P12\P12_Soutenance\

#df_billets_production_Soutenance = pd.read_csv(r"D:\BDD\OCR\P12\P12_Soutenance\NOM_FICHER.csv", sep = ',')
```

2. Lancer l'application



3. AFFICHAGE ET EXPORT DU RESULTAT

Etape 3 - AFFICHAGE DU RESULTAT

```
print("RESULTAT SIMPLE :")
display(df_resultat[['id', 'Authenticité', 'Auth_Proba_%']])
```

RESULTAT SIMPLE :

	id	Authenticité	Auth_Proba_%
0	A_1	False	1.2
1	A_2	False	0.0
2	A_3	False	0.0
3	A_4	True	98.2
4	A_5	True	100.0

```
print("RESULTAT COMPLETS :")
display(df_resultat)
```

RESULTAT COMPLETS :

	diagonal	height_left	height_right	margin_low	margin_up	length	id	Authenticité	Auth_Proba_%
0	171.76	104.01	103.54	5.21	3.30	111.42	A_1	False	1.2
1	171.87	104.17	104.13	6.00	3.31	112.09	A_2	False	0.0
2	172.00	104.58	104.29	4.99	3.39	111.57	A_3	False	0.0
3	172.49	104.55	104.34	4.44	3.03	113.20	A_4	True	98.2
4	171.65	103.63	103.56	3.77	3.16	113.33	A_5	True	100.0

Etape 4 - EXPORT DES RESULTATS

```
#EXPORT DES RESULTATS :
```

```
df_resultat.to_csv(r"D:\BDD\OCR\P12\P12_Sorties\Resultats_Authenticite_AA\MMDDHHMM.csv", index=False)
```



- I – Présentation
- II – Analyse Exploratoire des Données (EDA) et Traitements de données
- III – Modélisation basée sur le K-means
- IV – Modélisation supervisée
- V – Choix du modèle final
- VI – Présentation de l'application
- VII – Conclusion et Perspectives



VII – Conclusion et Perspectives

- **Conclusion générale :**
Modèle **performant** développé pour **prédire l'authenticité d'un billet** à partir des caractéristiques géométriques.
- **4 approches comparées :**
 - Modèles supervisés : Régression Logistique, Random Forest, KNN
 - Méthode non supervisée : K-means avec transformation PCA
- **Le Random Forest se démarque : précis, robuste, avec TPR parfait, et FPR minimisée**
 - 100% de vrais billets détectés (Recall = 1.0)
 - Faux positifs minimisés à 1.8%
 - ROC-AUC à 0,9999
- **Perspectives d'évolution :**
 - **Industrialisation** du modèle dans une application dédiée (prévu dans le projet).
 - **Surveillance continue des performances** sur cas réels.
 - **Enrichissement du modèle** par :
 - Nouvelles données collectées
 - Ajout potentiel d'autres variables (ex : poids du papier, signature UV...)
 - **Formation des agents** à l'usage de l'outil et à la compréhension des résultats.

Merci !

Merci !



ANNEXE I.C-Documentation RGPD

CARACTERISTIQUES TECHNIQUES

- **DPO** : Monsieur X., DPO pour l'ONCFM
- **Responsable du traitement interne** : Prestataire Y
- **Finalité** (légal et légitime) :
Détecter les Faux Billets (Objectif de l'ONCFM)
- **Durée de Conservation** : 10 ans (durée de conservation courant secteur bancaire, conservation des données pour nouvelle entrainement)
(procédure de destruction à mettre en place)
(données non personnelles mais sensibles)
- **Analyse d'impact** :
 - peu sensible : données non personnelles.
 - sensible : méthode de détection de Faux billets
- **Droits des personnes** :
 - Non Applicable
- **Organisation à prévoir avec DPO et Secteur Data de l'entreprise** :
 - **Stockage centralisé et sécurisé des données**
 - **Règle d'accès à ces données**
 - Règle de destruction des données
 - Référencement de l'usage des données
(traitement et personne y ayant accès)
- **Remarque** : données non personnelles, mais sujet sensible

TRAITEMENT DES DONNEES :

- **Vérification de l'intégrité des données**
(analyse de doublons, traitement explicite des valeurs manquantes, pas de valeurs aberrantes)
- Principe de **proportionnalité et de pertinence**:
suppression des colonnes inutiles (Pas de colonne inutile)
- Principe de **confidentialité** :
 - données non personnelles, mais sensibles
 - Règles d'accès aux données à mettre en place

FIN !

FIN !

